# От данных к решениям

## Роль визуализации в цикле ML

**Занятие 1.2 · Лекция · 90 минут**

Интеллектуальный анализ и визуализация данных
Модуль 1 · Методология анализа и визуализации данных
Интегрированный поток: бакалавриат и магистратура

**Преподаватель:** Большаков Анатолий Афанасьевич, доцент, канд. техн. наук
**Ассистент:** Булдакова Мария Алексеевна

12.09.2026 · Санкт-Петербург

# Мост: что сделано и что сегодня

### Неделя 1

- Правила игры: треки, рубрикатор, команды
- Практикум 1.4: рабочие среды проверены

### Сегодня

- Открываем сквозной кейс: SOC и карточка инцидента
- В 12:00 — практика 1.5: фиксация треков, проверка инструментов

# Масштаб задачи

**240 000**

карточек-алертов в сквозном датасете курса
*(учебный датасет на основе реальных логов SOC)*

# Откуда берётся поток

тысячи событий в секунду → сбор и корреляция (**SIEM**) → **карточки-алерты**

# Шум преобладает

В отдельные периоды **более половины** карточек — ложноположительные срабатывания

Проверка каждой — минуты времени дежурного аналитика

# Цена ошибок сортировки

**Пропущенный инцидент**

Компрометация данных, простой бизнеса, репутация

**Ложная тревога**

Остановленные процессы, потраченные часы смены

# «Усталость от алертов»

Неделя пустышек — аналитик закрывает карточки по привычке.

Однажды он закрывает **настоящий инцидент**.

# Формула мира, в котором мы работаем

01 Огромный поток
02 Шум преобладает
03 Обе ошибки дороги
04 Время каждой проверки ограничено

# Название дисциплины — две половины конвейера




## Интеллектуальный анализ

## Визуализация данных

# Половины не существуют друг без друга

Анализ без визуализации — «чёрный ящик», которому не доверяют

Визуализация без анализа — красивые картинки над шумом

# Визуализация на каждом шаге ML-цикла

- Разведка данных → **модуль 2**
- Оценка модели → **3.1–3.2**
- Объяснение модели (XAI) → **3.3–3.4**
- Коммуникация результата → **модуль 4**

# SOC — центр мониторинга ИБ

Непрерывный мониторинг, выявление и координация реагирования

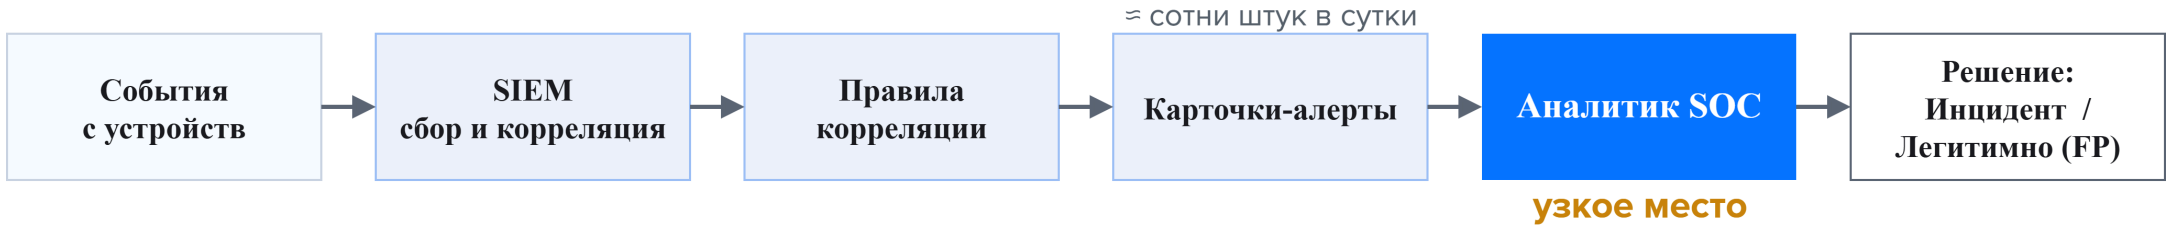
Дежурные аналитики работают посменно, круглосуточно.
Их единица работы — **карточка**.

# SIEM — система сбора и корреляции

Собирает события со всех устройств → нормализует →
применяет **правила корреляции**

Сработало правило → SIEM создаёт **алерт** — карточку для проверки

# Конвейер сортировки алертов



# Сортировка алертов (триаж)

Аналитик проверяет карточку и выносит вердикт:

**«Инцидент»** — тревога подтверждена, запускается реагирование
**«Ложноположительное срабатывание»** — тревога ложная, карточка закрыта

По этой метке размечен наш датасет

# Критичность — первый, грубый фильтр

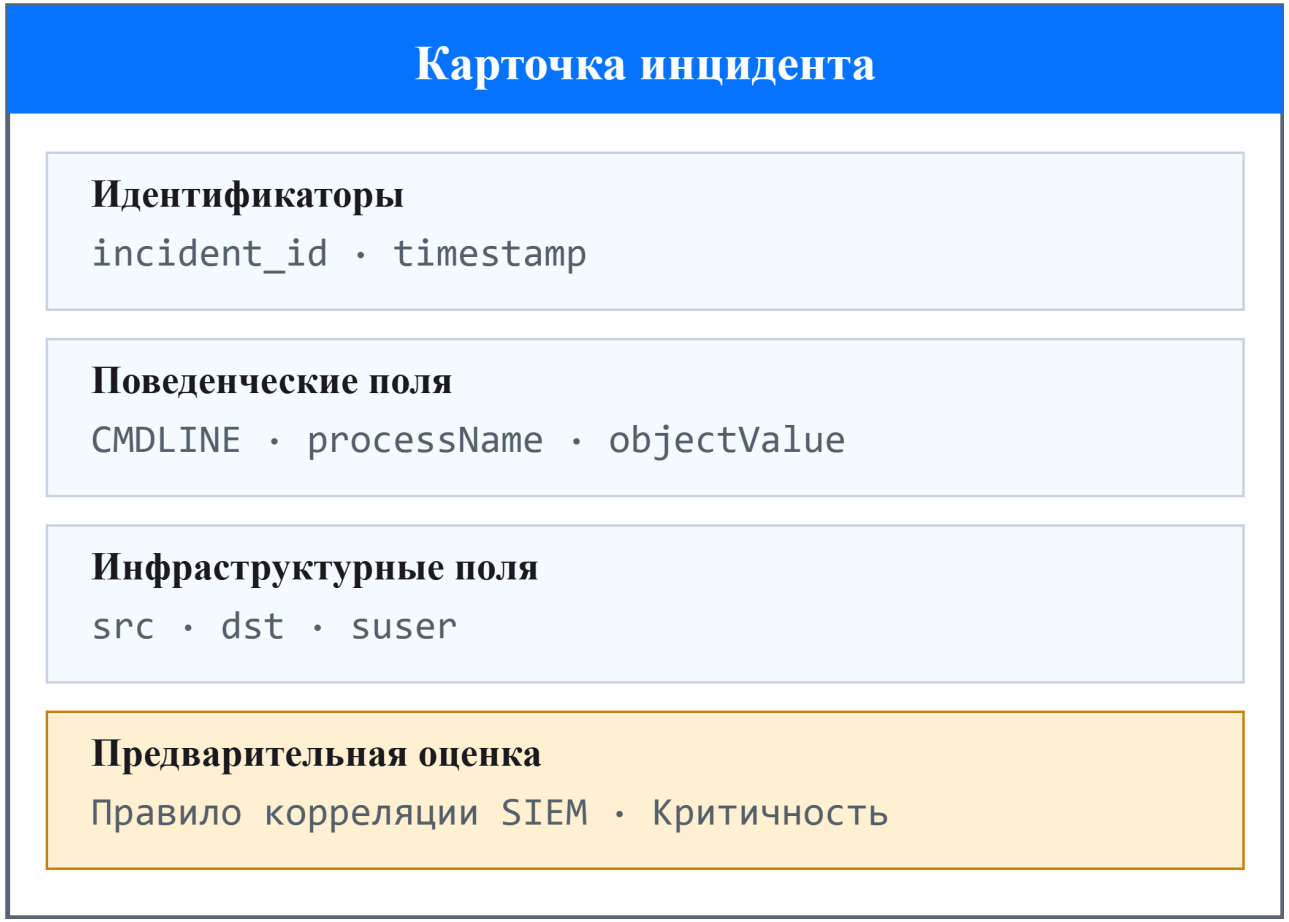
Правило SIEM присваивает приоритет:
критическая · высокая · средняя · низкая

Критические проверяются первыми. Но правила ошибаются:
«низкая» критичность не гарантирует, что атаки нет

# Где самое слабое звено конвейера?

SIEM обрабатывает миллионы событий в секунду.
Проверяет карточки — **человек**:
скорость мышления, внимание падает к третьему часу смены

# Карточка инцидента: четыре группы полей



# Идентификаторы

`incident_id` — уникальный номер карточки
Ссылка на событие в дашборде, отчёте, коде

`timestamp` — момент события
Ночная суббота и рабочий полдень — разные миры

# Поведенческие поля: «что делал процесс»

`CMDLINE` — полная командная строка запуска

`processName` — имя исполняемого файла

`objectValue` — значение объекта: ключ реестра, файл, параметр

Типовые программы работают с типовыми командами.

Нестандартное в командной строке — заслуживает взгляда

# Инфраструктурные поля: «кто и куда»

`src` — IP источника (рабочая станция, сервер)
`dst` — IP цели обращения
`suser` — учётная запись

Внутренний или внешний адрес, привилегии учётной записи — каждый факт меняет прочтение карточки

# Предварительная оценка

**Правило корреляции SIEM** — что именно «насторожило» систему
**Критичность** — предварительный приоритет

Это то, что система уже «подумала» — не приговор

# Демонстрационная карточка

```
INC-2026-004817 · 2026-08-14 02:31:07 · Критичность: Высокая
Правило:  Подозрительное выполнение PowerShell с обфускацией
src 10.12.4.87 → dst 203.0.113.147 · suser CORP\a.ivanov
processName  powershell.exe
CMDLINE      powershell.exe -nop -w hidden -enc JABzAD0A...
objectValue  HKCU\...\Run\OneDriveStandaloneUpdater
```

# Читаем как аналитик: рабочая гипотеза

- Три часа ночи — легитимной деловой активности минимум
- `-w hidden -enc` — скрытый запуск и обфускация команды
- Ключ автозагрузки — классическое закрепление в системе
- Внешний `dst` — сам по себе не криминал
- Учётная запись обычного сотрудника — он вообще в курсе?

**Гипотеза: возможное закрепление вредоносного кода.**

Из полей — вопросы для проверки

# Интерактив «Дежурная смена»

> Вам на проверку — три карточки. На каждую не более минуты: решение — «эскалация» или «закрыть».

| Карточка 1 · рабочий полдень | Карточка 2 · 03:00 | Карточка 3 · рабочее время |
|---|---|---|
| Антивирус обновил базы<br>Загрузка подписанного<br>процесса вендора | PowerShell с обфускацией<br>как в демонстрационном<br>примере | Пользователь открыл PDF<br>из письма · сработало правило<br>на макросы |

# Что не хватило?

Почти всегда ответ — **контекст**:
история этой машины и этого пользователя, что было до и после

Карточка — снимок одного события, а не вся правда

# ML-модель-советчик: что меняется

Обучена на размеченной истории → для каждой карточки —
**оценка вероятности** того, что это инцидент

# Советчик — не решающий

Финальный вердикт — за аналитиком:
вероятность + опыт + контекст, которого у модели нет

**Human-in-the-loop** — человек в контуре управления
(аккуратный разбор — занятие 1.3)

Полезный совет должен быть **понятен** → XAI, модуль 3

# Поля, которых SIEM не знает

| Поле | Значение |
|---|---|
| `Fact_label` | Истинная метка: 1 — инцидент, 0 — легитимно |
| `y_pred` | Предсказание модели |
| `y_pred_proba` | Вероятность предсказания |

Роль — на практике 1.5. Сейчас запомните: есть «ответы» и есть «подсказка»

# Курс — интеграционный

Модели и метрики → дисциплины ML и статистики
Запросы к данным → базы данных
Контекст атак → операционные системы, сети ЭВМ и телекоммуникации
Код → программная инженерия

**Наш вклад — собрать это в работающий продукт на сквозном кейсе**

# Итоги

01 Мир кейса: сотни тысяч карточек, шум преобладает, обе ошибки дороги
02 Конвейер: события → SIEM → правила → карточки → аналитик
03 Карточка — четыре группы полей
04 Модель — советчик; решение за человеком; совет должен быть объясним

# Сегодня и на неделю

### Сегодня, 12:00 — практика 1.5

- Фиксация треков
- Проверка инструментов: Qlik · Taipy
- Знакомство с датасетом

### Самостоятельная работа

- «Меню кейсов» — к 19.09.2026
- К. Андерсон, главы о data-driven подходе — к 1.3

# Далее: занятие 1.3

## Понятийный аппарат анализа данных

DIKW · Data-Driven и Data-Informed · сигнал и шум · TP/TN/FN/FP

**Вопросы?**