Когнитивные основы восприятия информации

Занятие 2.1 · Лекция · 90 минут

Интеллектуальный анализ и визуализация данных
Модуль 2 · Информационный дизайн и дескриптивная аналитика
Интегрированный поток: бакалавриат и магистратура

Преподаватель: Большаков Анатолий Афанасьевич, доцент, канд. техн. наук
Ассистент: Булдакова Мария Алексеевна

26.09.2026 · Санкт-Петербург

Модуль 2: где мы находимся

Лекция	Тема	Статус
2.1	Когнитивные основы восприятия информации	**сегодня**
2.2	Принципы информационного дизайна: Data-ink ratio, junk charts	далее
2.3	Систематизация визуализаций и анатомия дашборда	далее
2.4	Визуализация для разведочного анализа данных	далее
2.5–2.6	Практики: BI — Qlik Sense · ML — Taipy	4 сессии по 50 мин

Порядок осознанный: сегодня — человек, который смотрит; затем — правила читаемого экрана

Мост: что вы принесли из модуля 1



Переход между уровнями не автоматический: каждый шаг требует проверки

DIKW-проекция кейса: цена FP · цена FN · кто принимает решение · что автоматизируем · где участие человека обязательно

Форма представления — часть качества решения

> Если между результатом модели и решением находится человек, форма представления информации становится частью качества решения.

- Модель рассчитывает оценку положительного класса — но вердикт формируется из того, что аналитик **увидел, сопоставил и проверил**
- Один и тот же скор `y_pred_proba`: таблица на 500 строк против выделенной карточки — разные решения
- Информационный дизайн — производственный фактор качества решения, как качество модели

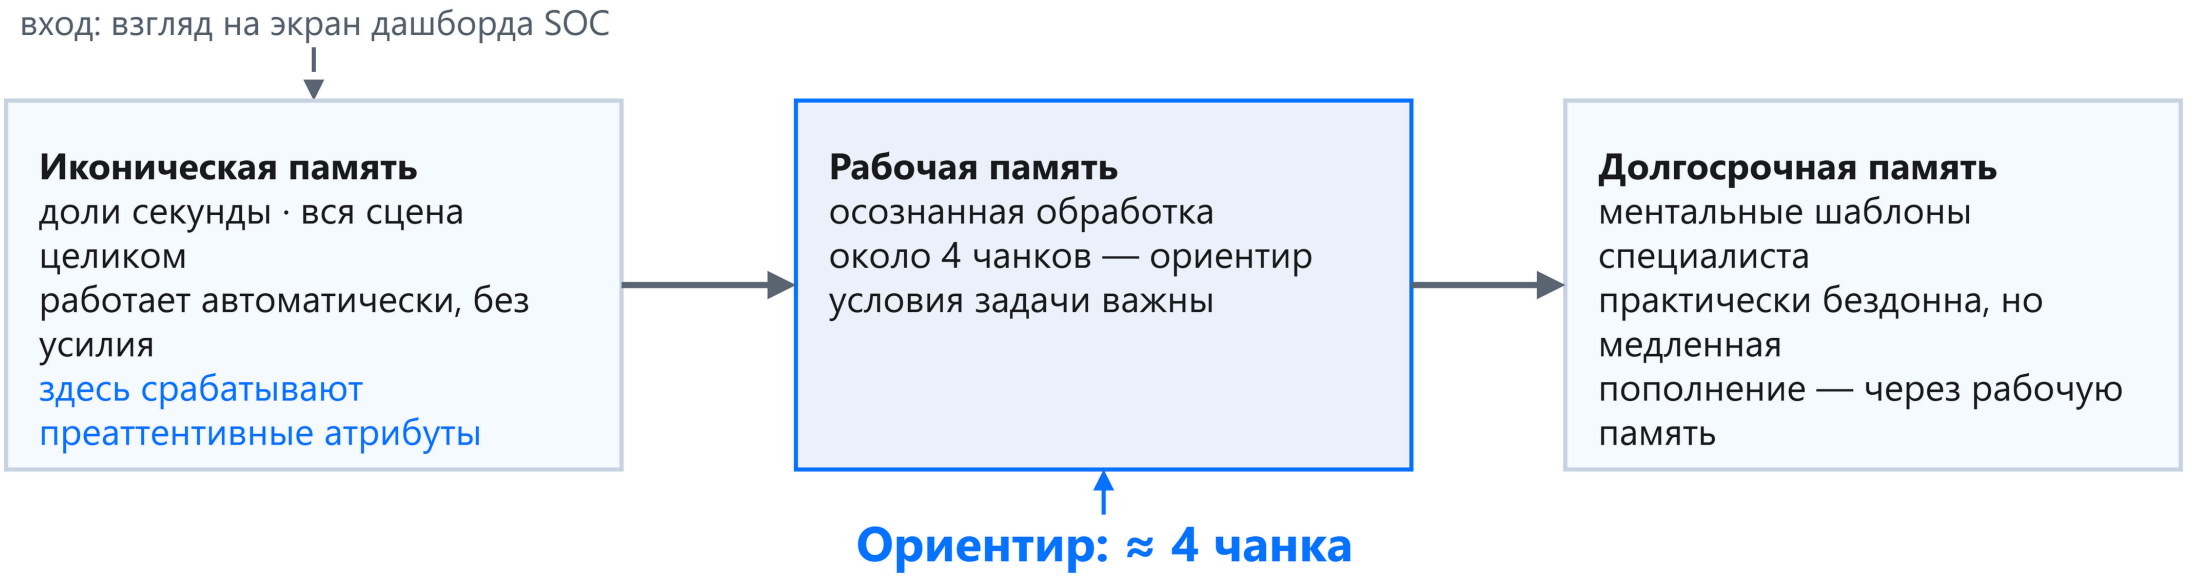
Экран не фотография

Восприятие — не копирование картинки, а активная сборка. На каждом этапе — потери:

- часть сцены считывается **мгновенно и целиком** — до всякого осознанного усилия
- часть — **медленно и по частям**, в узком окне осознанной обработки
- часть — не доходит до осознания вовсе; что-то — искажается через опыт

Три следствия для дизайна: быстрые каналы — для срочных сигналов · осознанная обработка — с жестким лимитом · шаблоны специалиста — не ломать

Конвейер восприятия: три памяти



Задача информационного дизайна — облегчать работу внимания:
группировать связанное, сохраняя доступ к деталям

Узкое место: рабочая память

- Классическая оценка — «семь ± два» (Миллер, 1956); это не правило для экрана
- Оценка Коуэна (2001) — около четырех чанков при определенных условиях

≈ 4 чанка

Ориентир для задач удержания информации, а не жесткий предел числа элементов интерфейса. Группировка снижает нагрузку на внимание

Пять полей карточки: цена разрозненного размещения

Аналитик открывает карточку алерта и сопоставляет пять разрозненных полей:

- `src` — источник события
- `dst` — назначение
- `suser` — учетная запись
- `Правило корреляции SIEM`
- модельный скор `y_pred_proba`

Пять разрозненных полей усложняют сопоставление → переключения внимания. В шумном потоке алертов это может усиливать «усталость от алертов»; четыре — не жесткая граница

Долгосрочная память: ментальные шаблоны

Опытный аналитик узнает картину мгновенно — бесплатно для рабочей памяти:

- всплеск `Suspicious_Login` по выходным вечерам от одной учетной записи `suser` → готовый шаблон «легитимная ночная активность администратора»

Следствие для дизайна: шаблоны работают только при консистентном интерфейсе. Критичность «сегодня цветом, завтра размером, послезавтра положением» — шаблоны не формируются, каждый экран читается с нуля

Вернемся к SNR: шум снижает читаемость

Три вида шума — не смешивать:

Вид шума	Что это	Инструмент борьбы
Шум входного потока	Лишние алерты в сортировке	Модель, порог (модуль 1)
FP модели	Качество конкретной модели, не то же, что шум потока	Метрики, порог
Визуальный шум экрана	Элементы без информации, занимающие внимание	Информационный дизайн (модуль 2)

Шумный поток × шумный экран — двойное давление на аналитика

Интерактив 1. Найди сигнал — попытка 1

> Найдите строку с другой учетной записью. Работаем только глазами. Поднимите руку, когда нашли.

```
10.0.12.4    10.0.8.19    svc_backup
10.0.91.2    10.0.8.19    svc_backup
10.0.44.1    10.0.8.19    svc_backup
10.0.12.4    10.0.31.5    svc_backup
10.0.44.1    10.0.8.19    svc_backup
10.0.91.2    10.0.8.19    svc_backup
10.0.12.4    10.0.8.19    svc_backup
10.0.31.5    10.0.8.19    svc_backup
10.0.44.1    10.0.8.19    svc_backup
10.0.12.4    10.0.8.19    a.ivanov
10.0.91.2    10.0.8.19    svc_backup
10.0.31.5    10.0.8.19    svc_backup
```

Интерактив 1. Попытка 2 и вывод

> Та же матрица. Найдите строку. Сравните время и усилие с попыткой 1.

```
10.0.12.4    10.0.8.19    svc_backup

10.0.91.2    10.0.8.19    svc_backup

10.0.44.1    10.0.8.19    svc_backup

10.0.12.4    10.0.31.5    svc_backup

10.0.44.1    10.0.8.19    svc_backup

10.0.91.2    10.0.8.19    svc_backup

10.0.12.4    10.0.8.19    svc_backup

10.0.31.5    10.0.8.19    svc_backup

10.0.44.1    10.0.8.19    svc_backup

10.0.12.4    10.0.8.19    a.ivanov

10.0.91.2    10.0.8.19    svc_backup
```

Преаттентивные атрибуты

Преаттентивные атрибуты — визуальные свойства, которые обрабатываются за доли секунды, до осознанного внимания

Класс	Вопрос, на который отвечает	Пример в триаже
Цветовой тон	какого цвета?	класс вердикта
Интенсивность, насыщенность	насколько ярко?	подсветка критичной карточки
Размер, толщина	насколько крупно?	вес KPI
Положение	где находится?	очередь вердиктов
Форма	какой формы?	тип источника события

Движение тоже работает преаттентивно, но в операционных интерфейсах — осторожно

Атрибуты в действии

В каждой строке один объект отличается ровно одним атрибутом — найдите его

Цветовой тон  в триаже: сигнальный цвет критичной карточки

Интенсивность  в триаже: уровень тревоги KPI дрифта

Размер, толщина  в триаже: вес KPI на дашборде

Положение  в триаже: порядок карточки в очереди вердиктов

Форма  в триаже: тип источника события

Вывод: атрибут переносит поиск из рабочей памяти (секунды чтения строк) в иконическую память (доли секунды) — без чтения и без легенды

Правило сигнального цвета

> Сигнальный цвет — только для того, что требует немедленной реакции аналитика.

- Атрибут «выгорает» от массовости: красным выделена половина потока — сигнала нет
- Рабочая дисциплина: **нейтральная база + один фокус** (максимум два)
- Куда направить фокус, решает цена ошибки из DIKW-проекции, а не вкус дизайнера

Почему радужные палитры не работают

Цветовой тон — категория, а не упорядоченная шкала: между красным и зеленым нет «больше»

- радуга на количественной шкале создает ложные границы и «горбы» там, где данные меняются плавно
- сравнить два значения по радуге почти невозможно

Рабочее правило курса: количественные шкалы — через упорядоченные средства (яркость, насыщенность, длина); тон — для категорий и акцентов

Зачем гештальт: группировать связанное

Ориентир Коуэна: около четырех чанков в задачах удержания информации, не лимит элементов дашборда

- **гештальт-паттерны** — правила зрительной группировки: элементы, размещенные определенным образом, мозг объединяет в один воспринимаемый объект
- связанные KPI на общей плашке → один блок с внутренней структурой
- 40 строк, сгруппированных по секциям → несколько групп

Задача дизайна: **облегчить поиск и сопоставление, группируя связанные элементы**

Шесть гештальт-паттернов

Как мозг группирует элементы в целое — у каждого паттерна свой пример из триажа

1 · Близость



`src` и `dst` — вплотную: одна пара события

2 · Сходство



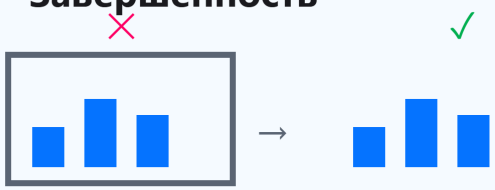
один цвет = одна сущность на всех экранах: легенда не нужна

3 · Общая область

1 274 · 34 % · 12

3 KPI на общей плашке = 1 блок «состояние смены»

4 · Завершенность



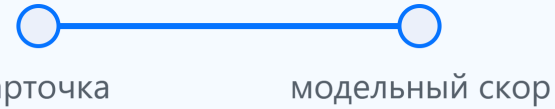
глаз сам достроит границу: рамки вокруг графиков избыточны

5 · Продолжение



суточный таймлайн алертов читается как один непрерывный процесс

6 · Связь



линия — утверждение о связи: соединяют только реально связанное

Паттерн работает только там, где есть реальная связь: группировка несвязанного — ложное утверждение о структуре данных

Близость и сходство в карточке инцидента

Близость — рядом = группа:

- `src` и `dst` стоят вплотную: это направление события
- блоки разных сущностей разведены воздухом
- расстояние — тоже дизайн: бесплатный и ненавязчивый

Сходство — одинаковый цвет = одна сущность на всех экранах:

- карточка в потоке, строка в логах, точка на таймлайне — один цвет
- легенда объясняет, что искать; сходство сразу показывает, где

Общая область и завершенность: KPI-блок

Общая область — плашка собирает разрозненное в один объект:

- три KPI — объем потока, доля `y_pred = 1`, очередь вердиктов — на светлой плашке
- три связанных показателя → один видимый блок «состояние смены»

Завершенность — мозг сам достраивает контуры:

- щели между панелями читаются как границы
- жирные рамки вокруг графиков повторяют то, что глаз достроит сам

Прием: **группируй плашкой, а не рамкой**

Продолжение и связь: таймлайн алертов

Продолжение — глаз продлевает линию вдоль ее направления:

- суточный таймлайн алертов читается как один непрерывный процесс
- всплески и провалы видны сразу, без сравнения столбиков

Связь — самый сильный паттерн: соединенные линией элементы связываются даже против цвета и формы

- линия — утверждение о связи: проводят ее только там, где связь действительно есть

Вывод блока: гештальт облегчает навигацию

- KPI-ряд на плашке — блок · пара `src`–`dst` рядом — связь · таймлайн — процесс
- данные не сжаты: связанные элементы легче искать и сравнивать

Граница метода: гештальт упаковывает то, что действительно связано. Группировка несвязанного — ложное утверждение о структуре данных

> Перед объединением на экране спросите: что здесь связано по смыслу?

Гештальт в SIEM-интерфейсах: еще примеры

- **близость:** правила корреляции SIEM сгруппированы по семействам — сетевые, учетные записи, процессы — отступами и заголовками секций
- **сходство:** пользователи — один оттенок, узлы — другой; сущность переносится через все экраны панели
- **общая область:** фон блока «очередь вердиктов» отделяет смену деятельности от потока raw-алертов

По каждой панели: какой паттерн сработал и что сломается, если его убрать?

Идея Кливленда–МакГилла: точность считывания измерима

- люди декодируют значения из разных кодировок с **разной точностью**
- в опытах 1984 года оценка по **положению** оказалась точнее оценок по **длине** и по **углу** на сравнивавшихся графиках

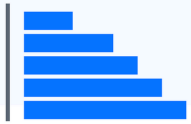
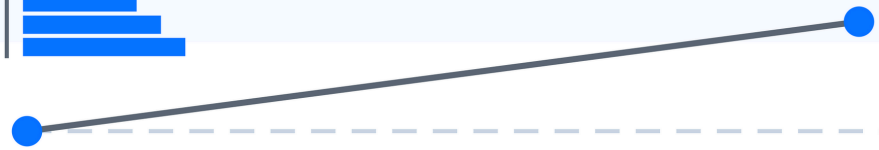
Смысл для нас: кодировка влияет на точность сравнения в конкретной задаче

- для точного сравнения скоров лучше выбирать положение или длину, а не площадь

Оговорка: семь строк далее — учебные примеры, не экспериментальный рейтинг. В гипотезе авторов длина, направление и угол были в одной группе; цветовой тон в нее не входил

Лестница кодировок: от точных к грубым

Учебная схема, не рейтинг опытов: длина и угол — одна группа гипотезы; цветовой тон в нее не входил

1	**Положение на общей шкале**		точно
2	**Положение на несвязанных шкалах**		почти точно
3	**Длина**		точно
4	**Угол, наклон**		для обзора
5	**Площадь**		грубо
6	**Объем**		избегать
7	**Цветовой тон, насыщенность**		категории, акцент

Правило: точное сравнение — верх лестницы · обзор и категории — нижние ступени допустимы

Точные кодировки: положение и длина

Верх лестницы — задачи, где ответ должен быть точным:

- **ранжирование:** топ-10 карточек по `y_pred_proba` — столбцы от общей нулевой линии, сортировка по убыванию
  - порядок задают скоры; график помогает заметить их различия
- **точечное сравнение:** активность `src` по времени — диаграмма рассеяния, положение на общей шкале

Точная кодировка упрощает сопоставление; вердикт зависит и от других свидетельств

Грубые кодировки: угол, площадь, объем, цвет

Строки схемы не означают запрета на другие задачи:

Кодировка	Законно	Недопустимо
Угол, наклон	направление тренда	точное сравнение долей
Площадь	пузырьки на карте: где крупнее, обзорно	точное сравнение величин
Объем	—	в аналитике избегать
Цветовой тон	категории, акцент	количественная шкала

Проверочная фраза: **«какой вопрос — такая кодировка»**

Типовые ошибки выбора кодировки

> Кодировку выбирает аналитик под вопрос данных, а не библиотека по умолчанию.

- **радужная палитра** как количественная шкала — тон не упорядочен
- **точное сравнение по площади** — размеры пузырьков; в круговой сравнивают прежде всего углы
- **круговая для ранжирования** — доли алертов по `Правило корреляции SIEM`: глаз сравнивает углы; столбцы дают общую шкалу для сравнения

Ошибки массово приходят из настроек по умолчанию BI-систем

Границы применимости иерархии

Иерархия точности — не единственный критерий качества графика:

- **плотность экрана:** сотни точек — иногда оправдано грубое, но компактное кодирование
- **привычность:** знакомый график читается быстрее точного, но незнакомого
- **характер задачи:** обзорная панель и детальный разбор требуют разной точности

Порядок применения: вопрос → кодировка нужной точности → проверка композиции. Иерархия — инструмент выбора, не автоматический закон

Как изучали точность: эксперименты по декодированию

Кливленд и МакГилл (1984) провели два опыта:

- **столбцы:** сравнение по положению на общей шкале и по длине; **столбцы и круговые:** по положению и углу
- участники быстро оценивали, какой **процент** меньшая величина составляет от большей, без измерений
- ошибка: $\log_2(|\text{названный процент} - \text{истинный процент}| + 0{,}125)$

Вывод: в этих графиках положение дало более точные оценки. Семь строк слайда 25 не были проверены как единый рейтинг; длина, направление и угол — одна группа гипотезы авторов

Условный макет: триаж-панель дежурного аналитика

> Учебные карточки составлены на структуре полей датасета `iavd_incidents_raw`; значения и сценарии условные. Реальные дашборды — на практике 2.5.

В макете ничего случайного: каждый элемент отрабатывает принцип лекции

1. общий вид — сколько смысловых объектов на панели
2. выноски — KPI-группа и подсветка карточек
3. кодировка скора — и связь с вердиктом аналитика

Общий вид макета

Учебный макет — триаж-панель дежурного аналитика

1

Объем потока · 1 274 / смена	Доля y_pred = 1 · 34 %	Очередь вердиктов · 12 карточек

2

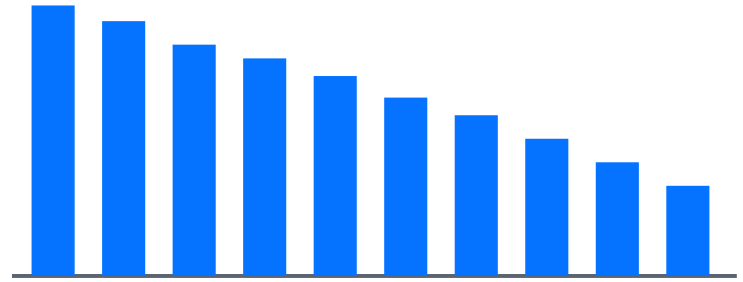
incident_id	src → dst	Критичность	y_pred_proba
INC-10412	10.0.12.4 → 10.0.8.19	высокая	0,92
INC-10413	10.0.44.1 → 10.0.31.5	**критическая**	0,87
INC-10414	10.0.91.2 → 10.0.8.19	средняя	0,61
INC-10415	10.0.31.5 → 10.0.8.19	низкая	0,34

Динамика алертов за сутки



3

Топ-10 карточек по y_pred_proba



длина — точное сравнение скоров

4

Требует вердикта аналитика

12 карточек · решение принимает человек, не модель

1 KPI-блок: общая область + близость — три метрики воспринимаются как группа

2 Подсветка карточки: преаттентивный цвет — только критичные случаи

3 Топ-10 по скору: длина — точное сравнение по иерархии кодировок

4 Очередь вердиктов: оценка модели не равна вердикту аналитика

Данные условные · поля iavd_incidents_raw; значения и сценарии учебные

Разбор: KPI-группа и подсветка карточки

KPI-ряд — три метрики на общей плашке нейтрального цвета, выровнены, от других блоков — воздух:

- общая область + близость: три цифры → один блок «состояние смены»
- уберите плашку → три разрозненных объекта: их сложнее найти и сопоставить

Подсветка карточек — строка с высокой `Критичностью` и высоким скором, единственный насыщенный цвет панели:

- нейтральная база + один фокус: красных строк мало — сигнал пробивает выгоревшее внимание
- подсветить «все подозрительное» → «усталость от алертов» своими руками

Скор длиной — и вердикт аналитика

Топ-10 по `y_pred_proba` — столбцы от общей нулевой линии, по убыванию:

- точное сравнение скоров = вопрос «насколько» → длина от общей нулевой линии (строка 3 схемы)
- скоры задают очередность; длина помогает аналитику заметить разницу между соседними карточками

Плашка «Требует вердикта аналитика» — визуальное воплощение Human-in-the-loop:

данные → информация → свидетельства → оценка модели → **вердикт аналитика** → операционное действие

Интерактив 2. Клиника графиков: правила

За 2 минуты сделать диагноз по схеме:

1. Какая визуальная кодировка использована?
2. Ссоответствует ли она вопросу зрителя?
3. Чем заменить — кодировка, которая помогает ответить на вопрос точнее

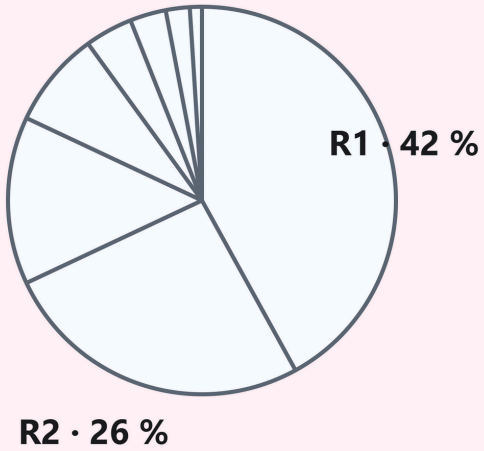
> «Некрасиво» — не диагноз. Диагноз — в терминах иерархии кодировок.

Дефекты в пациентах намеренные и не единственные — кто найдет больше двух, молодец

Пациент 1 и пациент 2

Клиника графиков: два пациента — дефекты намеренные

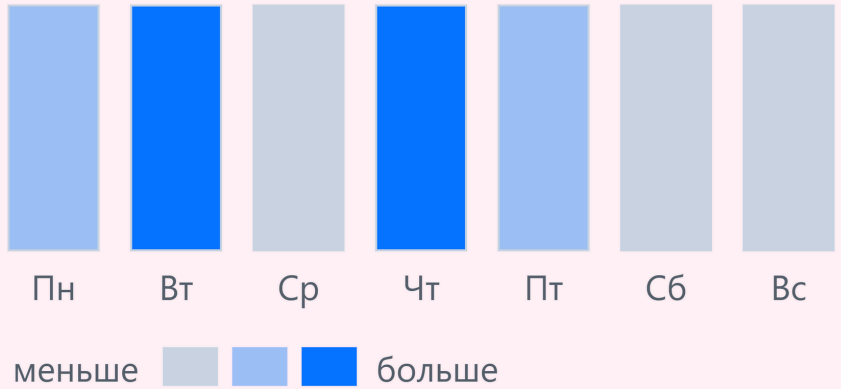
Пациент 1 · «Распределение алертов по правилам SIEM»



Доли потока по правилам R3–R8: 14 · 8 · 4 · 3 · 2 · 1 %

Пациент 2 · «Нагрузка по дням недели»

величина закодирована оттенком одного цветового тона



Диагноз: 1 — какая кодировка · 2 — соответствует ли она вопросу · 3 — чем заменить (ступень выше по лестнице)

Данные условные · поля iavd_incidents_raw; значения и сценарии учебные

Разбор диагнозов

Пациент 1 — круговая «Распределение алертов по правилам корреляции SIEM»:

- использован **угол** (строка 4 схемы) для задачи точного ранжирования
- замена: столбцы от нулевой линии, сортировка по убыванию

Пациент 2 — динамика по дням, значения оттенками одного тона:

- **насыщенность** (строка 7 схемы) для вопроса «насколько»
- замена: длина; пик недели выделить единственным сигнальным акцентом

Нашли третий дефект? Тяжелые рамки, плотные сетки, легенды-дубли — **визуальный мусор**, тема занятия 2.2

Мост к 2.2: хорошую кодировку можно погубить шумом

Визуальный шум (информационный мусор) — элементы, которые не несут новой информации, но занимают внимание и пространство: рамки, избыточные сетки, легенды-дубли, декоративные заливки

- шум экрана действует согласованно с шумом потока и FP модели — вспомните SNR

Часть пикселей экрана должна нести данные; остальные — чистый убыток. Насколько велик убыток и как его измерить — вопрос Э. Тафти

Занятие 2.2: принципы Тафти · соотношение данных и чернил (Data-ink ratio) · мусорные диаграммы (junk charts) · квартет Энскомба · практикум «до → после»

Итоги: что вы теперь знаете и умеете

Результат	Что внутри
Знать	конвейер восприятия и ориентир ≈ 4 чанка; преаттентивные атрибуты и правило сигнального цвета; гештальт-паттерны; учебную иерархию кодировок
Уметь	ставить диагноз графику в терминах иерархии; выбирать кодировку под вопрос данных; применять паттерны к элементам карточки инцидента
Владеть	экспресс-оценкой «какой вопрос — какая кодировка»; дисциплиной «нейтральная база + один фокус»

Критерий «Информационный дизайн» защиты весит 30 % — сегодня его рабочая основа

Самостоятельная работа

Срок — к занятию 2.2 (03.10.2026)

Обязательно:

1. Изучить гл. 4 «Направьте внимание аудитории» из книги Нафлик «Данные: визуализируй, расскажи, используй».
2. По DIKW-проекции кейса выбрать 3–5 ключевых полей из `iavd_incidents_raw`; кодировки для `Критичности`, `Вердикта`, количества алертов (карточек) — с обоснованием по иерархии (5–7 предложений)
3. Эскиз обзора алертов (карточек): что выделяется преаттентивно, как группируется, чем кодируется `Вердикт`

Дополнительно:

1. Один «больной» график из открытых источников + диагноз (2–3 предложения) — разберем на практике 2.5
2. Как выбор кодировок влияет на риск FN и издержки FP в проекте команды (допущение курса: типичный FN дороже типичного FP)
3. Просмотреть работы Коуэна (URL: https://pubmed.ncbi.nlm.nih.gov/11515286/) и Кливленда–МакГилла (URL: https://www.jstor.org/stable/2288400).

Вопросы?

СРС — к занятию 2.2 (03.10.2026) · вопросы по материалу — в чате потока
Практика 2.5, сессия 1: реальные дашборды · BI — Qlik Sense · ML — Taipy. Приносите DIKW-проекции и предложения к обзору карточек